

# Sannolikhetskalkyl 2

*Föreläsningsanteckningar*

---

John Möller

---

# Contents

<b>I</b>	<b>Introduktion</b>	<b>1</b>
<b>1</b>	<b>John Möllers notationer</b>	<b>1</b>
<b>2</b>	<b>Formalia</b>	<b>1</b>
<b>3</b>	<b>Innehåll av kursen</b>	<b>1</b>
<b>4</b>	<b>Föreläsning</b>	<b>1</b>
4.1	Några exempel	1
4.2	Repetition	2
4.3	Egenskaper hos $\mathcal{P}$	2
4.4	Några fler definitioner	2
4.5	Tolkning av sannolikhet	5
<b>II</b>	<b>Flerdimensionella stokastiska variabler</b>	<b>6</b>
<b>III</b>	<b>Mer om betingade väntevärden</b>	<b>6</b>
<b>5</b>	<b>Betingning</b>	<b>6</b>
<b>6</b>	<b>Motivering, kontinuerliga fallet</b>	<b>6</b>
<b>7</b>	<b>Betingad varians</b>	<b>8</b>
<b>IV</b>	<b>Transformer</b>	<b>10</b>
<b>8</b>	<b>potensserier och satser om SGF</b>	<b>11</b>
<b>9</b>	<b>Momentgenererande funktioner</b>	<b>13</b>
<b>V</b>	<b>Misc notes</b>	<b>15</b>
<b>10</b>	<b>Stuff</b>	<b>15</b>
<b>11</b>	<b>Stuff 2</b>	<b>15</b>
<b>12</b>	<b>3.1a</b>	<b>15</b>

13 Problem 5	16
14 Problem 19	16

---

# Introduktion

## 1 John Möllers notationer

Jag kommer alltid ha  $\subset$  betyder delmängd (som kan vara likamed). Det har d.v.s en motsvarighet till  $\leq$  (och inte  $<$ ).

## 2 Formalia

Daniel Ahlberg

[Kursbroschyr](#) Litteratur: An intermediate course in probability, 2nd Edition, Springer (2009).

- 6 Stycken frivilliga inlämningsuppgifter, som ger bonuspoäng till tentan.
- Muntlig redovisning (mer information skall komma).

Det enda obligatoriska är tentan (men de vill väldigt gärna att man går på muntliga redovisning).

## 3 Innehåll av kursen

Målet är att få fördjupad förståelse av grundläggande begrepp och metoder.

Speciellt kolla på:

- Flerdimensionella stokastiska variabler, speciellt den multivariata normalfördelningen.
- Tekniker såsom betingning och transformationer.
- Konvergensbegrepp inom sannolikheteorin.

## 4 Föreläsning

Syftet med sannolikhetskalkyl är att skapa en matematisk grund för att analysera modeller för slumpmässiga fenomen

### 4.1 Några exempel

**Exempel** (Smittspridning). F/ Vad krävs för att en smittad skall ge upphov till ett stort utbrott?

$R_0 :=$  förväntat antal nya fall en person smittad individ ger upphov till .

Om  $R_0 > 1$  medför att ett stort utbrott är möjligt. Medan om  $R_0 < 1$  medför det att ett stort utbrott är ej möjligt. (förgreningsprocesser)

**Exempel** (Kortblandningar). Hur många gånger och hur ska man blanda för att man ska vara "nöjd"? Att dela i två är kräver typ bara 7 gånger. Kanske tusen gånger på ett annat sätt.

(markovkedjor)

## 4.2 Repetition

Det mest grundläggande är ett sannolikhetsrum.

**Definition 4.1** (Sannolikhetsrum). Ett sannolikhetsrum är en trippel  $(\Omega, \mathcal{F}, \mathcal{P})$ .

- Mängden  $\Omega$  kallas utfallsrummet,
- mängden  $\mathcal{F}$  är en samling delmängder av  $\Omega$  kallade händelser.
- Funktionen  $\mathcal{P} : \mathcal{F} \rightarrow [0, 1]$   
Funktionen uppfyller följande krav:
  - $\mathcal{P}(A) \geq 0$  för alla  $A \in \mathcal{F}$
  - $\mathcal{P}(\Omega) = 1$
  - Om  $A_1, A_2, \dots$  är parvis disjunkta händelser så gäller  $\mathcal{P}(\bigcup_{k=1}^{\infty} A_k) = \sum_{k=1}^{\infty} \mathcal{P}(A_k)$Funktionen  $\mathcal{P}$  kallas för sannolikhetsmått.

**Kommentar** (Formellt extrakrav). För formell korrekthet krävs att  $\mathcal{F}$  är en  $\sigma$ -algebra. Man har det för att man ska kunna ta snitt och så vidare... (överkurs)

**Kommentar** (Tolkning). Om man upprepar så kommer den relativa frekvensen närma sig sannolikheten för händelsen.

## 4.3 Egenskaper hos $\mathcal{P}$

Från definition härleds att

- $\mathcal{P} \in [0, 1]$  för alla  $A \in \mathcal{F}$
- $\mathcal{P}(\emptyset) = 0$
- Om  $A$  och  $B$  är disjunkta, så är  $\mathcal{P}(A \cup B) = \mathcal{P}(A) + \mathcal{P}(B)$ .
- Om  $A \subset B$ , så  $\mathcal{P}(A) \leq \mathcal{P}(B)$

Låt  $(\Omega, \mathcal{F}, P)$  vara ett sannolikhetsrum.

## 4.4 Några fler definitioner

**Definition 4.2** (betingning). Låt  $A, B \in \mathcal{F}$  vara två händelser och antag att  $P(B) > 0$ . Den betingade sannolikheten för  $A$  givet  $B$  definieras som

$$P(A|B) := \frac{P(A \cap B)}{P(B)}.$$

**Definition 4.3** (Oberoende).  $A$  och  $B$  är oberoende om

$$P(A \cap B) = P(A) \cdot P(B).$$

**Definition 4.4** (Stokastisk variabel). En stokastisk variabel är en ( mätbar ) funktion  $X : \Omega \rightarrow \mathbb{R}$ .

Fördelningsfunktion  $F_X : \mathbb{R} \rightarrow [0, 1]$  av  $X$  ges av

$$F_X := P(X \leq x).$$

Och i teorin (John: är inte helt säker på vad det innebär) bestämmer den stokastiska variabeln.

Två klasser av fördelningar. Låt massfunktionen av  $X$  vara

$$p_X(x) := P(X = x).$$

**Kommentar.**  $p_X(x) > 0$  för som mest uppräknligt många värden på  $X$ .

(Illustration)

- $X$  har en diskret fördelning om  $F_X(x) = \sum_{y \leq x} p_X(y)$  för alla  $x \in \mathbb{R}$ .
- $X$  har en kontinuerlig fördelning om det existerar en (integrerbar) funktion  $f_X : \mathbb{R} \rightarrow [0, \infty)$  sådan att  $F_X(x) = \int_{-\infty}^x f_X(y) dy$  för alla  $x \in \mathbb{R}$ .

$f_X$  kallas täthetsfunktion behöver inte vara unik (för integraler).

**Exempel** (Täthetsfunktionen är ej unik). Båda följande exempel ger en täthet för en likformig fördelning.  
funktionen

$$f_1(x) = \begin{cases} 1 & \text{om } x \in [0, 1] \\ 0 & \text{annars} \end{cases}.$$

Sen kan vi definiera

$$f_2(x) = \begin{cases} 1 & \text{om } x \in [0, 1] \text{ och } x \neq 0.5 \\ 0 & \text{annars} \end{cases}.$$

**Definition 4.5** (Väntevärde). Väntevärdet av en stokastisk variabel  $X$  definieras som

$$E[X] := \begin{cases} \sum_{x \in \mathbb{R}} x \cdot p_X(x) & \text{om } X \text{ diskret} \\ \int_{-\infty}^{\infty} x f_X(x) dx & \text{om } X \text{ kontinuerlig} \end{cases},$$

givet att dessa är väldefinierade/ändliga.

Väntevärde ger det förväntade värdet man får från en stokastisk variabel.

**Kommentar.** Eftersom  $p_X(x)$  är nollskild för ett uppräknligt antal punkter så kommer summan vara uppräknlig.

**Definition 4.6** (Varians). Variansen av  $X$ , då  $E[X]$  är väldefinierat, ges av följande uttryck

$$\text{Var}(X) := E[(X - E[X])^2] = E[X^2] - E[X]^2.$$

**Uppgift 4.1.** Visa att om  $\text{Var}(X) = 0$  bör vara ekvivalent med att det existerar ett  $c \in \mathbb{R}$  så att:

$$P(X = c) = 1.$$

Låt  $X$  och  $Y$  vara stokastiska variabler definierade på samma sannolikhetsrum.

**Definition 4.7** (Bivariata fördelning). Bivariata fördelningen för  $X$  och  $Y$  är

$$F_{X,Y}(x, y) := \mathcal{P}(X \leq x, Y \leq y).$$

**Definition 4.8** (Oberoende).  $X$  och  $Y$  är oberoende om

$$F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y),$$

för alla  $x, y \in \mathbb{R}$ .

**Definition 4.9** (Kovarians). Kovariansen av  $X$  och  $Y$  är

$$\text{Cov}(X, Y) := E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y].$$

Om  $X$  och  $Y$  är oberoende så gäller att

$$E[XY] = E[X]E[Y],$$

så

$$\text{Cov}(X, Y) = 0.$$

**Definition 4.10** (Korrelationskoefficienten). Korrelationskoefficienten av  $X$  och  $Y$  ges av

$$\rho_{X,Y} := \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}.$$

Den är alltid mellan  $-1$  och  $1$ .

**Sats 4.1** (Markovs olikhet). Om  $X$  är icke-negativt så gäller

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

**Sats 4.2** (Chebyshevs olikhet). Om  $E[X]$  existerar, så gäller

$$P(|X - E[X]| > a) \leq \frac{\text{Var}(X)}{a^2}.$$

## 4.5 Tolkning av sannolikhet

Kom ihåg tolkningen av sannolikheter som den relativa frekvensen med vilken en händelse inträffar då ett experiment upprepas oberoende av varandra många gånger.

**Fråga.** Varför stämmer detta?

Låt oss betrakta något "experiment"  $(\Omega, \mathcal{F}, P)$  och någon händelse  $A$ . Låt

$$X_k = \begin{cases} 1 & \text{om } A \text{ inträffar omgång } k \\ 0 & \text{annars} \end{cases}.$$

Dessa variabler är oberoende om experimentet utförs oberoende av tidigare omgångar.

Den relativa frekvensen för  $A$  i  $n$  omgångar är

$$\frac{1}{n} \sum_{k=1}^n X_k.$$

**Fråga.** Gäller det att  $\frac{1}{n} \sum_{k=1}^n X_k \approx P(A)$ ?

Observera att

$$\begin{aligned} E \left[ \frac{1}{n} \sum_{k=1}^n X_k \right] &= \frac{1}{n} \sum_{k=1}^n E[X_k] = E[X_1] \\ &= 0 \cdot P(A^c) + 1 \cdot P(A) = P(A). \end{aligned}$$

$$\begin{aligned} \text{Var} \left( \frac{1}{n} \sum_{k=1}^n X_k \right) &= \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) \\ &= \frac{1}{n} P(A)[1 - P(A)]. \end{aligned}$$

Chebyshevs olikhet ger

$$\begin{aligned} P \left( \left| \frac{1}{n} \sum_{k=1}^n X_k - P(A) \right| > \epsilon \right) &\leq \frac{\text{Var}(\frac{1}{n} \sum_{k=1}^n X_k)}{\epsilon^2} \\ &= \frac{P(A)[1 - P(A)]}{n \cdot \epsilon^2}. \end{aligned}$$



Detta är litet om  $n$  är stort, och blir mindre då  $n$  ökar. Detta motiverar tolkningen.

Dag

2

# Flerdimensionella stokastiska variabler

| Exempel.

Dag

4

## Mer om betingade väntevärden

### 5 Betingning

Om  $(X, Y)$  är en diskret slumpvektor så är den betingade fördelningen av  $Y$  givet  $X = x$  fördelningen för  $Y$  med avseende på  $P(\star|X = x)$ .

Om  $(X, Y)$  kontinuerlig så är den betingade fördelningen för  $Y$  givet  $X = x$  den fördelning med täthet

$$f_{Y|X=x}(y) := \frac{f_{X,Y}(x, y)}{f_X(x)},$$

för alla  $y \in \mathbb{R}$ .

### 6 Motivering, kontinuerliga fallet

Låt  $X$  vara en kontinuerlig variabel. Låt också  $\Delta > 0$ , och sätt  $x_k = \Delta \cdot k$  och  $I_k = (x_{k-1}, x_k]$ .

Eftersom Riemann-integralen är gränsvärdet av en summa, så får vi

$$P(X \in (a, b]) = \int_a^b f_X(x) dx = \lim_{\Delta \rightarrow 0} \sum_k f_X(x_k) \Delta.$$

där summan gör över alla  $k$  så att  $x_k \in (a, b]$ .

Låt  $A$  vara en händelse. Ett rimligt försök är att definiera

$$P(A|X = x) = \lim_{\Delta \rightarrow 0} P(A|x \in (x - \Delta, x]).$$

**Exempel.** Antag  $A = \{X \geq 0\}$ . Ovan definitionen ger då

$$\begin{aligned} P(A|X = 0) &= \lim_{\Delta \rightarrow 0} P(A|X \in (-\Delta, 0]) \\ &= \lim_{\Delta \rightarrow 0} \frac{P(X = 0)}{P(X \in (-\Delta, 0])} = 0. \end{aligned}$$

Observera dock

$$\lim_{\Delta \rightarrow 0} P(A|X \in (0, \Delta]) = \lim_{\Delta \rightarrow 0} \frac{P(X \in (0, \Delta])}{P(X \in (0, \Delta])} = 1.$$

Att definerna  $P(A|X = x)$  med ett gränsvärde ger alltså problem.

Låt oss anta att

$$P(A|X = x) = \lim_{\Delta \rightarrow 0} P(A|X \in (x - \Delta, x])$$

för de flesta  $x \in \mathbb{R}$ . Notera att

$$\begin{aligned} P(A, X \in (a, b]) &\approx \sum_k P(A, X \in I_k) \\ &= \sum_k P(A|X \in I_k) \cdot P(X \in I_k). \end{aligned}$$

Ungefär så är  $P(X \in I_k) \approx f_X(x_k) \cdot \Delta$ . Om vi nu skickar  $\Delta \rightarrow 0$  så får vi att  $P(A|X = x)$  borde uppfylla följande ekvation:

$$P(A, X \in (a, b]) = \int_a^b P(A|X = x) f_X(x) dx.$$

(Ovan är ekvation \*\*) Lösning den betingade sannolikheten av  $A$  givet  $X$  som någon funktion  $x \mapsto P(A|X = x)$  som uppfyller ekvationen ovan.

**Kommentar.** Funktionen  $x \mapsto P(A|X = x)$  behöver inte vara unika, men två funktioner som uppfyller ekvationen är lika för nästan alla  $x \in \mathbb{R}$ .

Då är  $(X, Y)$  är en kontinuerlig slumpvektor så är (\*\*) ekvivalent med (sätt  $A = \{Y \leq y\}$ ,  $a = -\infty$ )

$$F_{X,Y}(x, y) = \int_{-\infty}^x F_{Y|X=u} f_X(u) du.$$

**Kommentar.** Vår tidigare definition av  $F_{Y|X=u}(y)$  ges av

$$F_{Y|X=u}(y) = \int_{-\infty}^y f_{Y|X=u} du.$$

Insatt i HL får vi

$$\begin{aligned} HL &= \int_{-\infty}^x \int_{-\infty}^y \frac{f_{X,Y}(u, v)}{f_X(u)} dv f_X(u) du \\ &= \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(u, v) dudv \\ &= F_{X,Y}(x, y). \end{aligned}$$

Alltså är värde definitioner konsistenta med diskussionen ovan.

**Exempel.** Låt oss anta att antalet röda blodkroppar i ett blodprov följer en Poisson-fördelning, men att parametern varierar mellan individer.

Detta kan beskrivas via följande modell: Antalet blodkroppar  $X$  följer följande samband:

$$X|M = m \sim \text{Po}(m),$$

med  $M \sim F$ , där  $F$  är någon känd eller okänd fördelning. Fördelningen för  $(X, M)$

beskrivs här indirekt. Om  $F$  är diskret så får vi

$$P(X = k, M = l) = P(X = k|M = l) \cdot P(M = l).$$

Där  $P(X = k|M = l) \sim \text{Po}(m)$  och  $P(M = l) \sim F$ .

I fallet då  $F$  är kontinuerlig så får vi från (\*\*) att

$$P(X = k, M \in (a, b]) = \int_a^b P(X = k|M = m) \cdot f_M(m) dm.$$

**Exempel.** Antag  $M \sim \exp(1)$ .

$$\begin{aligned} P(X = k) &= \int_0^\infty P(X = k|M = m) \cdot e^{-m} dm \\ &= \int_0^\infty e^{-m} \frac{m^k}{k!} \cdot e^{-m} dm \\ &= \frac{1}{2^{k+1}} \int_0^\infty 2^{k+1} \cdot e^{-2m} \cdot \frac{m^k}{k!} dm \\ &= \frac{1}{2^{k+1}} \end{aligned}$$

Sista steget fås genom att se att integranden är tätheten av en T-fördelning  
Alltså har  $X$  en geometrisk fördelning.

## 7 Betingad varians

**Definition 7.1** (Betingad varians). Låt  $(X, Y)$  vara en (kontinuerlig eller diskret) slumpvektor. Den betingade variansen för  $Y$  givet  $X = x$  är

$$\text{Var}(Y|X = x) := E[(Y - E[Y|X = x])^2|X = x],$$

förutsatt att  $E[Y|X = x]$  är väldefinierat.

För varje  $x \in \mathbb{R}$  får vi ett värde på funktionen  $V(X) := \text{Var}(Y|X = x)$ . Dock är  $V(X)$  en stokastisk variabel och vi skriver  $V(X) = \text{Var}(Y|X)$ .

**Sats 7.1.** Antag att  $E[Y^2] < \infty$ . Då gäller

$$\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}(E[Y|X]^2).$$

**Bevis.** Notera att

$$\begin{aligned} \text{Var}(Y) &= E[(Y - E[Y])^2] \\ &= E[(Y - E[Y|X] + E[Y|X] - E[Y])^2] \\ &= E[(Y - E[Y|X])^2] \\ &\quad + E[E[Y|X] - E[Y]^2] \\ &\quad + 2E[(Y - E[Y|X])(E[Y|X] - E[Y])]. \end{aligned}$$

Låt de tre sista termerna i kalkulationen vara  $A, B$  respektive  $C$ .

$$\begin{aligned} A &= E \left[ (Y - E[Y|X])^2 \right] \\ &= E \left[ E \left[ (Y - E[Y|X])^2 | X \right] \right] \\ &= E [\text{Var}(Y|X)]. \end{aligned}$$

$$\begin{aligned} B &= E \left[ (E[Y|X] - E[Y])^2 \right] \\ &= \text{Var}(E[Y|X]). \end{aligned}$$

$$\begin{aligned} C &= E [E [(Y - E[Y|X])(E[Y|X] - E[Y])|X]] \\ &= E [(E[Y|X] - E[Y]) (E[Y|X] - E[Y|X])] \\ &= 0. \end{aligned}$$

□

**Exempel.** En pinne har längd 1 bryts på en lokformigt vald punkt. Upprepa. Låt  $X$  beteckna första brytpunkten och  $Y$  den andra.

Alltså  $Y|X = x \sim \text{likf}[0, x]$  och  $X \sim \text{likf}[0, 1]$ .

Vi har

$$\begin{aligned} E[Y|X = x] &= \frac{x}{2} \\ \text{Var}(Y|X = x) &= \frac{x^2}{12}. \end{aligned}$$

Vi får att

$$\begin{aligned} \text{Var}(E[Y|X]) &= \text{Var}\left(\frac{X}{2}\right) \\ &= \frac{1}{4} \text{Var}(X) \\ &= \frac{1}{4} \cdot \frac{1}{12} \cdot E[\text{Var}(Y|X)] \\ &= \frac{1}{12} \cdot \frac{1}{3}. \end{aligned}$$

Sats ger

$$\text{Var}(Y) = \frac{1}{4} \cdot \frac{1}{12} + \frac{1}{3} \cdot \frac{1}{12} = \frac{7}{144}.$$

**Uppgift 7.1.** Låt  $(X, Y)$  vara en slumpvektor med täthet

$$f_{X,Y}(x, y) = \begin{cases} \frac{1}{2} & 0 \leq x \leq 1, 0 \leq y \leq 1 \\ \frac{1}{8} & 1 < x \leq 3, 1 < y \leq 3 \end{cases}.$$

- a) Bestäm den betingade tätheten för  $Y$  givet  $X = x$  för  $x \in [0, 3]$  b) Beräkna  $E[Y]$   
c) Avgör om  $X$  och  $Y$  är oberoende.

**Lösning 7.1.1.** a) Vi behöver  $f_X$

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)dy.$$

Rita upp på en xy graf.

**Sats 7.2.** Låt  $X : \Omega \rightarrow \mathbb{R}^n$  vara en kontinuerlig slumpvektor med densitet  $f_X$ . Om  $g, g^{-1} \in C^1$ . Låt  $g : S \rightarrow T \subset \mathbb{R}^n$  vara en bijektion och sätt  $Y = g(X)$ . Då är  $Y : \Omega \rightarrow \mathbb{R}^n$  kontinuerlig med densitet

$$f_Y(y) = \begin{cases} f_X(g_1^{-1}(y), \dots, g_n^{-1}(y)) \cdot |J| & y \in T \\ 0 & y \notin T \end{cases},$$

där  $J$  är jakobianen för  $g^{-1}$ .

**Exempel.** Låt  $X$  och  $Y$  vara oberoende  $N(0,1)$ -fördelade. Visa att  $X+Y$  och  $X-Y$  är oberoende  $N(0,2)$ -fördelade.

Dag

5

# Transformer

Låt  $X_1, X_2, \dots, X_n$  vara oberoende och likafördelade.

Låt

$$S_n = X_1 + \dots + X_n.$$

I kontinuerliga fallet gäller

$$P(X_1 + X_2 \leq x) = \int_{-\infty}^x \int_{-\infty}^{\infty} f_{X_1}(v) f_{X_2}(u-v) dv du.$$

Genom transformer kan vi ersätta multipelintegralen med multiplikation.

**Definition 7.2** (sannolikhetsgenererande funktionen). Låt  $X$  vara icke-negativ och heltalsvärd stokastisk variabel.

Den sannolikhetsgenererande funktionen (SGF) av  $X$  är

$$g_X(t) := \sum_{n \geq 0} t^n \cdot P(X = n).$$

**Kommentar.**

$$\begin{aligned} g_X(0) &= P(X = 0), \\ g_X(1) &= \sum_{n \geq 0} P(X = n) = 1. \end{aligned}$$

**Kommentar.** För  $|t| \leq 1$  så

$$\begin{aligned} & \left| g_X(t) - \sum_{n=0}^{N-1} t^n P(X=n) \right| \\ & \leq \sum_{n=N}^{\infty} |t|^n \cdot P(X=n) \\ & \leq \sum_{n \geq N} P(X=n) \rightarrow 0, \end{aligned}$$

då  $N \rightarrow \infty$ .

Så för åtminstone  $|t| \leq 1$  så är  $g_X$  väldefinierad.

## 8 potensserier och satser om SGF

Låt  $(a_n)_{n \geq 0}$  vara en följd av rella tal och sätt

$$f(t) := \sum_{n=0}^{\infty} a_n t^n.$$

**Lemma 8.1.** Om  $f$  är väldefinierad (serien konvergerar) för  $|t| < 1$  så är  $f$  kontinuerlig och deriverbar med

$$f'(t) = \sum_{n \geq 1} n a_n t^{n-1},$$

där  $f'$  är väldefinierad för  $|t| < 1$ .

**Lemma 8.2.** Om  $\sum_{n \geq 0} a_n$  konvergerar, så gäller det att

$$\lim_{t \rightarrow 1^-} f(t) = \sum_{n \geq 0} a_n.$$

**Bevis.** Bevisas i kursen analysens grunder. □

**Sats 8.3.** Låt  $X, Y$  vara icke-negativa och heltalsvärda stokastiska variabler. Då gäller

$$g_X = g_Y \iff p_X = p_Y.$$

**Bevis.** Beviset av  $\leftarrow$  följer av definitionen.

Vi vill visa att  $g_X$  bestämmer  $p_X$ . Notera först att  $g_X(0) = P(X=0)$ . Eftersom  $g_X$  är väldefinierad för  $|t| < 1$  så ger Lemma 1 att

$$g'_X(t) = \sum_{n \geq 1} n \cdot t^{n-1} P(X=n).$$

Eftersom  $g'_X$  väldefinierad för  $|t| < 1$  kan vi fortsätta derivera. Samtliga ordningens derivata existerar och ges av

$$\begin{aligned} & g_X^k(t) \\ & = \sum_{n \geq k} n(n-1)(n-2) \dots (n-k+1) t^{n-k} \cdot P(X=n). \end{aligned}$$

Låt för  $t = 0$  får vi

$$g_X^{(k)}(0) = k!P(X = k).$$

Alltså bestämmer  $g_X$   $P(X = k)$  för varje heltal  $k \geq 0$ .  $\square$

**Sats 8.4.** Låt  $X_1, X_2, \dots, X_n$  vara oberoende icke-negativa och heltalsvärda stokastiska variabler. Sätt  $S_n = X_1 + \dots + X_n$ . Då gäller

$$g_{S_n}(t) = \prod_{k=1}^n g_{X_k}(t).$$

**Bevis.** Notera att för  $t \neq 0$  så gäller

$$g_X(t) \sum_{n \geq 0} t^n P(X = n) = E[t^X].$$

Detta ger

$$\begin{aligned} g_{S_n}(t) &= E[t^{X_1+X_2+\dots+X_n}] \\ &= E[t^{X_1}]E[t^{X_2}] \dots E[t^{X_n}] \\ &= \prod_{k=1}^n g_{X_k}(t). \end{aligned}$$

(Gäller också för  $t = 0$  eftersom kontinuerliga funktioner.)  $\square$

**Exempel.** Låt  $X_1, \dots, X_n$  vara oberoende bern( $p$ )-fördelade. Sätt  $S_n = X_1 + \dots + X_n$ . Per definition

$$\begin{aligned} g_{X_1}(t) &= P(X = 0) + tP(X = 1) \\ &= (1 - p) + tp. \end{aligned}$$

Enligt sats

$$\begin{aligned} g_{S_n}(t) &= (g_{X_1}(t))^n \\ &= ((1 - p) + tp)^n \\ &= \sum_{k=1}^n \binom{n}{k} (1 - p)^{n-k} (tp)^k. \end{aligned}$$

Låt  $Y \sim \text{Bin}(n, p)$ . Per definition

$$\begin{aligned} g_Y(t) &= \sum_{k=0}^n t^k P(Y = k) \\ &= \sum_{k=0}^n t^k \binom{n}{k} p^k (1 - p)^{n-k}. \end{aligned}$$

Alltså är  $g_{S_n} = g_Y$ , och enligt sats har  $S_n$  och  $Y$  samma fördelning.

## 9 Momentgenererande funktioner

**Definition 9.1** (Momentgenererande funktionen). Den momentgenererande funktionen av en stokastisk variabel  $X$  ges av

$$\Psi_X(t) := E[e^{tX}],$$

givet att det existerar något  $h > 0$  så att väntevärdet ovan är ändligt för  $|t| \leq h$ .

**Sats 9.1.** Låt  $X$  vara en stokastisk variabel för vilken  $\Psi_X(t)$  existerar för  $|t| < h$  för något  $h > 0$ . Då gäller

$$\begin{aligned} \text{(a)} \quad E[|X|^r] &< \infty && \text{för alla } r > 0 \\ \text{(b)} \quad \Psi_X^{(n)}(0) &= E[X^n] && \text{för } n \geq 1. \end{aligned}$$

**Bevis.** (a): Tag  $0 < t < h$ . Då gäller

$$\begin{aligned} E[e^{|tX|}] &\leq E[e^{tX} + e^{-tX}] \\ &= \Psi_X(t) + \Psi_X(-t) < \infty. \end{aligned}$$

Funktionen  $e^{tx}$  växer snabbare än  $x^r$ . Det vill säga för varje  $t > 0$  och  $r > 0$  så existerar  $C > 0$  så att

$$|x|^r \leq C \cdot e^{|tx|} \forall x \in \mathbb{R}.$$

Därmed gäller också, för dessa värden på  $r$  och  $t$ ,

$$E[|X|^r] \leq E[C \cdot e^{|tX|}] < \infty.$$

(b): Taylorutveckling ger

$$e^{tX} = 1 + \sum_{n=1}^{\infty} \frac{t^n \cdot X^n}{n!}.$$

Givet att  $|t| < h$  så existerar väntevärdet av ovan uttryck och ger

$$E[e^{tX}] = 1 + \sum_{n=1}^{\infty} \frac{t^n E[X^n]}{n!}.$$

Notera att högerledet är Taylorserien av  $e^{tx}$ . Därmed måste vi ha att

$$\Psi_X^{(n)}(0) = \frac{d^n}{(dt)^n} E[e^{tx}] = E[X^n].$$

□



**Exempel.** Låt  $Z \sim N(0, 1)$ . För alla  $t \in \mathbb{R}$  får vi att

$$\begin{aligned}\Psi_Z(t) &= E[e^{tZ}] \\ &= \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2 - 2tz}{2}} dz \\ &= - \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{(z-t)^2}{2} + \frac{t^2}{2}} dz \\ &= e^{\frac{t^2}{2}}.\end{aligned}$$

**Sats 9.2.** Låt  $X$  vara en stokastisk variabel och  $a, b \in \mathbb{R}$ . Då gäller

$$\Psi_{aX+b}(t) = e^{tb} \cdot \Psi_X(at),$$

givet att VL eller HL väldefinierat.

**Bevis.**

$$\begin{aligned}\Psi_{aX+b}(t) &= E[e^{t(aX+b)}] \\ &= e^{tb} \cdot E[e^{(ta)X}] \\ &= e^{tb} \cdot \Psi_X(at).\end{aligned}$$

□

**Exempel.** Låt  $Y \sim N(\mu, \sigma^2)$ . Då är

$$z = \frac{Y - \mu}{\sigma} \sim N(0, 1).$$

Därmed får vi

$$\begin{aligned}\Psi_Y(t) &= \Psi_{\mu+\sigma Z}(t) \\ &= e^{\mu t} \Psi_Z(\sigma t) \\ &= e^{\mu t} \cdot e^{t^2 \frac{\sigma^2}{2}} \\ &= e^{\mu t + t^2 \sigma^2 / 2}.\end{aligned}$$

**Sats 9.3.** Låt  $X_1, \dots, X_n$  vara oberoende stokastiska variabler med MGF som existerar för  $|t| < h$ , för något  $h > 0$ . Låt  $S_n = X_1 + \dots + X_n$ . Då gäller

$$\Psi_{S_n}(t) = \prod_{k=1}^n \Psi_{X_k}(t),$$

för  $|t| < h$ .

**Sats 9.4.** Om det existerar  $h > 0$  så att  $\Psi_X(t)$  och  $\Psi_Y(t)$  existerar och är lika för  $|t| < h$ , då är  $X$  och  $Y$  likafördelade.

# Misc notes

## 10 Stuff

$$N \sim \text{Po}(\lambda)$$

$$X|N = n$$

## 11 Stuff 2

$\bar{X} \sim \text{Exp}(1/\alpha)$  (line of repairing device)  $\bar{Y} \sim \text{Exp}(\frac{1}{n\alpha})$  (time of single aeorisoion?)

$$P_n = P(\bar{Y} \leq \bar{X})^n.$$

$$\begin{aligned} P(\bar{Y} \leq \bar{X}) &= P(\bar{Y} \leq \bar{X} | \bar{X} \in (0, \infty]) \\ &= \int_0^\infty P(\bar{Y} \leq \bar{X} | \bar{X} = x) f_{\bar{X}}(x) dx \\ &= \int_0^\infty F_{\bar{Y}|\bar{X}=x}(x) f_{\bar{X}}(x) dx \\ &= \int_0^\infty P(\bar{Y} \leq x | \bar{X} = x) f_{\bar{X}}(x) dx \\ &= \int_0^\infty \left( \int_0^x F_{\bar{Y}|\bar{X}}(y) dy \right) f_{\bar{X}}(x) dx \\ &= \int_0^\infty \left( \int_0^x n\alpha e^{-n\alpha y} dy \right) \alpha e^{-\alpha x} dx. \end{aligned}$$

## 12 3.1a

$X|M = m \sim \text{Po}(m)$ ,  $M \sim \text{Exp}(a)$ . What is the distribution of  $X$ ?

Think always when encountering this law of total probability.

$$P(X = k | M = m) = e^{-m} \frac{m^k}{k!}, k = 0, 1, \dots$$

$$f_M(x) = \begin{cases} \frac{1}{a} e^{-\frac{x}{a}}, & x \geq 0 \\ 0, & \text{otherwise} \end{cases}.$$

Law of total probability:  $B_1, \dots, B_n$  disjoint events and  $B_1 \cup \dots \cup B_n = \Omega$ . Discrete case:

$$P(A) = \sum_k P(A|B_k) \cdot P(B_k).$$

Continuous case:

$$P(X = k) = \int_0^\infty P(X = k | M = m) f_M(m) dm.$$

Gamma distribution:

$$f(x, k, \theta) = \frac{x^{k-1} e^{-x/\theta}}{\theta^k \Gamma(k)}.$$

for  $x \geq 0, k, \theta > 0$ .

Gamma i  $k!$ .

It is needed when evaluating the integral.

## 13 Problem 5

$N, X_1, X_2$ , independent random variables.  $N \in \text{Po}(\lambda)$ .  $X_k \in \text{Be}(\frac{1}{2})$

$$Y_1 = \sum_{k=1}^N X_k$$

$$X_2 = NY_1.$$

Prove that  $Y_1$  and  $Y_2$  are independent.  $y_1, y_2 \geq 0$  We want to prove

$$P(Y_1 = y, Y_2 = y_2) = P(Y_1 = y_1)P(Y_2 = y_2).$$

$$P(Y_1 = y_1, N = y_1 + y_2).$$

You should condition in this case.

Condition on the random value.

## 14 Problem 19

$$f_{X,Y}(x, y) = \begin{cases} c, & 0 \leq x \leq 1, x^2 \leq y \leq x \\ 0, & \text{otherwise} \end{cases}.$$

$$E[X|Y = y]? \quad E[Y|X = x]$$

it ranges from  $x^2 \leq y \leq x$ .

kk